

# Tarea 5-Reconocimiento de Patrones- Felipe Neut

## I. MOTIVACIÓN

La detección de peatones es un problema altamente desafiante en el campo de detección de objetos, y cuyo estudio ha crecido significativamente en los últimos años con el aumento de veredas y ciclovías, de tal forma de evitar accidentes a peatones, detectar robos, entre otros usos que se le pueda dar.

## II. SOLUCIÓN PROPUESTA

Varias decisiones fueron basadas en la literatura en [1] recomendada en clases, la cual propone la utilización de HOG y *linear SVM* para este problema en particular.

Dicho lo anterior, a continuación se explicará la solución propuesta en esta tarea para cada ítem de interés.

→ **Extracción de Features:** Siguiendo la recomendación de la literatura, fue empleado el método de HOG, para el cual se utilizó un total de  $20 \times 10$  particiones o histogramas, y un total de 9 *bins*, que es justamente el valor recomendado por el autor de este método. Dichos valores, entregaron un total de 1800 *features* extraídas. Es importante destacar que se trabajó pasando las imágenes de color RGB a una escala de grises, para evitar complicaciones con falsas correlaciones de color.

→ **Selección de Features:** Se comenzó realizando un *clean* gracias al *Toolbox Balu*. Posteriormente se procedió a normalizar las *features*, para finalmente realizar una selección de 100 *features* mediante *SFS*. Con un total de 100 *features* se logró maximizar el *J* de *Fisher* a un valor elevado y estable.

→ **Cross-validation:** A diferencia de tareas anteriores, se empleó el conocido método de *cross-validation* con 10 *folders*, que si bien posee numerosos usos, en esta tarea en específico fue empleado para la extracción de 10 conjuntos de datos diferentes tanto para *training* ( $X_{train}$ ), como para *testing* ( $X_{test}$ ), manteniendo la proporción de 90 % para *training*, y 10 % para *testing* en cada una de las 10 iteraciones. Luego, se reportan los promedios de *accuracy*, *recall* y *precision* de estas 10 iteraciones. Una contra de este método es que se debe entrenar 10 veces distintas, no obstante, los resultados obtenidos son mucho más estables y confiables.

Se mencionó en *issues* del foro, que producto de la baja cantidad de datos se podía efectuar la selección de *features*, y una vez seleccionadas realizar *cross-validation* con las características seleccionadas (las 10 *folders* cuentan con las mismas características seleccionadas), que fue justamente lo realizado en esta tarea.

Para efectuar *cross-validation* se utilizó como base la función *Bev\_crosval()* del *Toolbox Balu*, la cual tuvo que ser levemente modificada en orden de poder realizar la obtención de *recall* y *precision*.

→ **Clasificadores utilizados:** Para decidir que clasificador utilizar en *cross-validation*, se utilizó la función *Bio\_plotfeatures()* del *ToolBox Balu* para analizar como estaban siendo repartidas las 2 clases para las *features* seleccionadas, observando una gran separación de las clases.

Esto, y la literatura en [1] llevaron a tomar como preferencia clasificadores lineales, tales como *linear SVM* y *LDA*. El tercer clasificador implementado fue una red neuronal con 3 *layers*, de 5, 5 y 6 nodos respectivamente. Aún así, se probaron otros clasificadores no lineales como *rbf-svm* y *KNN*, los que no presentaron una mejor *performance* que los clasificadores lineales como *LDA* y *linear SVM*.

→ **Obtención de recall, precision y accuracy:** Se implementó la función *desemp()*, que recibe como *input* la clasificación ideal y la clasificación estimada obtenida de *cross-validation* para cada carpeta. Ambas clasificaciones son *inputs* de la función *Bev\_confusion()*, la cual permite obtener los *True Positives* (TP), *False Positives* (FP), *False Negatives* (FN) y *accuracies*. Ya con dichos valores, simplemente se aplica la fórmula para obtener el *recall* ( $TP/(TP+FN)$ ) y *precision* ( $TP/(TP+FP)$ ) en base a la matriz de confusión para 2 clases. Como son 10 carpetas, se calcula la media y desviación estándar del *accuracy*, *recall* y *precision*.

## III. RESULTADOS

Los resultados para los clasificadores se muestran en la tabla a continuación, en la cual  $\bar{x}$  corresponde a la media y  $\sigma$  a la desviación estándar de la variable de estudio, respectivamente.

| Clasificador      | $\bar{x} \setminus \sigma$ Accuracy | $\bar{x} \setminus \sigma$ Recall | $\bar{x} \setminus \sigma$ Precision |
|-------------------|-------------------------------------|-----------------------------------|--------------------------------------|
| <i>Linear SVM</i> | 0.9975\0.0079                       | 1.0000\0.0000                     | 0.9952\0.0151                        |
| <i>LDA</i>        | 1.0000\0.0000                       | 1.0000\0.0000                     | 1.0000\0.0000                        |
| Redes neuronales  | 0.9725\0.0299                       | 0.9850\0.0242                     | 0.9623\0.0431                        |

Se puede ver la gran estabilidad y confiabilidad de los resultados al usar un método como *cross-validation*, lo que queda claro al ver los bajos valores de desviación estándar obtenidos, que hubieran sido mucho más elevados para otros métodos como *hold out*. Si bien los 3 clasificadores tuvieron valores muy buenos, los clasificadores lineales como *LDA* y *linear SVM* fueron aquellos con mejores resultados, lo cual es muy beneficioso dada su enorme rapidez y simplicidad. Sumado a lo anterior, se puede apreciar de los resultados la obtención de valores para *recall* y *precision* muy cercanos a 1, lo que significa que se están maximizando los verdaderos positivos, que es lo deseado en cualquier clasificación.

## IV. CONCLUSIONES

A modo de conclusión, se llegó a la obtención de resultados de *accuracy*, *recall* y *precision* altamente favorables y estables mediante extracción de *features* a través de HOG, selección de *features* por medio de *SFS*, y la implementación de *cross-validation* con 10 carpetas utilizando clasificadores lineales como *LDA* y *Linear SVM*.

## REFERENCIAS

- [1] Bhadra, T., Sonar, J., Sarmah, A., Kumar, C.J. "A Pedestrian Detection: A Survey of Methodologies, Techniques and Current Advancements". IJSRET (2015).